




은행 고객 이탈 요인 분석

4조 - 2015270301 이재혁 / 2015270335 이유원 / 2016270301 김지원

목차



- 은행 고객들의 세부 정보를 통해 고객들의 이탈 여부를 확인하고 이탈을 막기 위한 대책 강구

참고기사

은행권, 시니어 고객 확보 위한 마케팅 강화

국민은행, 은퇴자산관리전문 전용상담센터 오픈...금융·세무·부동산·법률 자문

승인 2020-09-28 11:58:29 | 이동은 기자 | deunJee@naver.com

승인 2020-09-28 11:58:29

[미디어펜=이동은 기자] 은행들이 은퇴를 앞둔 '시니어 고객'을 겨냥한 자산관리 컨설팅과 서비스 개발에 적극적으로 나서고 있다. 충분한 소비 여력을 보유하고 있는 5060 세대를 위해 종합자산관리, 은퇴 설계 등의 프로그램을 제공한다는 방침이다.



▲ 최재영 KB국민은행 연금사업본부장, 노지원 KB국민은행 광주 KB골드라이프센터장, 박기래 KB국민은행 광주종합금융센터 지역본부장, 김영길 KB국민은행 WM고객그룹 부행장이 광주 KB골드라이프센터에서 기념촬영을 하고 있다/사진=KB국민은행

금융 > 은행

20대와 점점 확대하는 시중은행, '마케팅 경쟁' 치열

김경찬 기자
kkch@

기사입력 : 2020-10-26 00:00

은행별 20대 특화 브랜드 런칭
맞춤형 상품·서비스 '눈길'



[한국금융신문 김경찬 기자] 시중은행들이 최근 10~20대 중심으로 고객층을 넓혀가는 가운데 차별화된 서비스를 제공하기 위한 특화 브랜드를 출시하고 있다. 특

히 각자 금융 브랜드를 통해 맞춤형 상품, 서비스, 마케팅을 펼쳐나가며 고객과의 접점을 넓혀나가고 있다. 금융의 플랫폼화가 가속화되면서 시중은행들은 플랫폼 활용에 능한 20대 고객들을 유치하기 위해 서비스를 개선하는 등 고객유치 경쟁이 치열하게 진행되고 있다.

◇ 20대 전용 브랜드 '잇달아' 런칭

[밀레니얼금융] 은행권, 1020세대 고객 잡기 마케팅 '열전'

박진영 기자 | 승인 2020.06.19 15:20 | 댓글 0

(시사오늘, 시사ON, 시사온=박진영 기자)

은행권이 1020세대 고객을 잡기 위해 다양한 마케팅 퍼포먼스를 펼치고 있다. 1020세대인 MZ세대가 다가올 미래 주요 고객층으로 떠오르면서, 이들을 선점하기 위한 경쟁이 치열하다. 더욱이 저금리 시대에 채테크에 관심을 두는 젊은층이 늘어나면서, 이들의 니즈를 충족하기 위해 다양한 혜택을 제공하는 금융상품을 내놓고 있다.



KB국민은행은 MZ세대를 겨냥한 맞춤형 금융상품인 'KB마이핏 통장'과 'KB마이핏 적금'을 새롭게 출시했다. ©KB국민은행

KB국민은행은 MZ세대를 겨냥한 맞춤형 금융상품인 'KB마이핏 통장'과 'KB마이핏 적금'을 새롭게 출시했다. 이번 상품은 '나에게 가장 딱 맞는 금융'이라는 콘셉트를 내세워 디지털 환경에 익숙한 MZ세대의 취향에 맞춰 설계됐다.

기사 출처 :

<http://www.mediapen.com/news/view/561818>

https://www.fntimes.com/html/view.php?ud=202010232157512703dd55077bc2_18

<https://www.sisaon.co.kr/news/articleView.html?idxno=114553>

- 정보통신 및 통신기술의 발전으로 인해 전자금융이 발전하였다. 그로 인해 은행들은 인공지능, 빅데이터 분석 등을 금융에 적용해 고객 맞춤형 서비스 제공함으로써 기존 고객의 이탈 방지 및 신규 고객의 유치를 위해 노력하고 있다. 은행 고객 관리를 효과적으로 하기 위해 이에 데이터 마이닝 기법을 사용한 해결 방안을 제시하고 이에 대한 결과물을 해석해 보고자 이 연구를 실시한다.

연구목적

- 데이터 마이닝 기법을 사용한 금융 서비스를 제공함으로써 은행의 기존 고객의 이탈 방지 및 신규 고객의 유치를 위한 관리를 보다 효율적으로 실시하기 위해 연구하게 되었다.

Row Data

<표 2-1> 은행 고객 이탈 여부 원본 분류 데이터

RowNumber	CustomerId	Surname	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
0	15634602	Hargrave	619	France	Female	42	2	0	1	Y	Y	101348.9	Y
1	15647311	Hill	608	Spain	Female	41	1	83807.86	1	N	Y	112542.6	N
2	15619304	Onio	502	France	Female	42	8	159660.8	3	Y	N	113931.6	Y
3	15701354	Boni	699	France	Female	39	1	0	2	N	N	93826.63	N
4	15737888	Mitchell	850	Spain	Female	43	2	125510.8	1	Y	Y	79084.1	N
5	15574012	Chu	645	Spain	Male	44	8	113755.8	2	Y	N	149756.7	Y
6	15592531	Bartlett	822	France	Male	50	7	0	2	Y	Y	10062.8	N
7	15656148	Obinna	376	Germany	Female	29	4	115046.7	4	Y	N	119346.9	Y
8	15792365	He	501	France	Male	44	4	142051.1	2	N	Y	74940.5	N
9	15592389	H?	684	France	Male	27	2	134603.9	1	Y	Y	71725.73	N
10	15767821	Bearce	528	France	Male	31	6	102016.7	2	N	N	80181.12	N
11	15737173	Andrews	497	Spain	Male	24	3	0	2	Y	N	76390.01	N
12	15632264	Kay	476	France	Female	34	10	0	2	Y	N	26260.98	N
13	15691483	Chin	549	France	Female	25	5	0	2	N	N	190857.8	N
14	15600882	Scott	635	Spain	Female	35	7	0	2	Y	Y	65951.65	N
15	15643966	Goforth	616	Germany	Male	45	3	143129.4	2	N	Y	64327.26	N
16	15737452	Romeo	653	Germany	Male	58	1	132602.9	1	Y	N	5097.67	Y
17	15788218	Henderson	549	Spain	Female	24	9	0	2	Y	Y	14406.41	N
18	15661507	Muldrow	587	Spain	Male	45	6	0	1	N	N	158684.8	N
19	15568982	Hao	726	France	Female	24	6	0	2	Y	Y	54724.03	N
20	15577657	McDonald	732	France	Male	41	8	0	2	Y	Y	170886.2	N

데이터 출처:

<https://www.kaggle.com/shrutimechlearn/churn-modelling>

테이블 정의서

<표 2-2> 데이터 전처리 후 테이블 정의서

변수번호	변수이름	변수유형	변수길이	레이블	변수설명
1	CustomerId	숫자	8	고객ID	은행 고객 식별을 위한 고유 ID
2	Surname	문자	15	성	고객의 성
3	CreditScore	숫자	3	신용 점수	고객의 신용 점수
4	Geography	문자	7	국가	고객이 속한 국가(프랑스, 독일, 스페인)
5	Gender	문자	6	성별	고객의 성별
6	Age	숫자	2	나이	고객의 나이

테이블 정의서


변수번호	변수이름	변수유형	변수길이	레이블	변수설명
7	Tenure	숫자	2	연도	고객이 은행과 함께한 연도 수
8	Balance	숫자	10	잔고	고객의 은행 잔고
9	NumOfProducts	숫자	1	상품의 수	고객이 활용하는 은행 상품의 수
10	HasCrCard	문자	1	카드	카드 소유 여부
11	IsActiveMember	문자	1	활동	고객의 활동 여부
12	EstimatedSalary	숫자	10	급여	추정된 급여
13	Exited	문자	1	이탈	이탈 여부

테이블 정의서

변수번호	변수이름	변수유형	변수길이	레이블	변수설명
14	Geography_Category_1	숫자	1	스페인	국적이 스페인인 고객
15	Geography_Category_2	숫자	1	독일	국적이 독일인 고객
16	Age_category	숫자	1	고객의 나이	범주화된 고객의 나이


기초 통계량 분석

(전체 자료의 수는 10000개)




<그림 3-1> Gender 변수 이탈여부 빈도 분석

성별의 경우
이탈에 비해 잔류인 남성이 약 5배 많고,
여성의 경우 이탈에 비해 잔류의 수가 약 3배 많다.




<그림 3-2> Geography 변수 이탈여부 빈도 분석

국가 별 특징으로
프랑스 고객의 잔류가 월등히 많고,
이탈의 경우 프랑스와 비슷하지만
독일 고객의 이탈이 약간 많다.



<그림 3-3> IsActiveMember 변수 이탈여부 빈도 분석


고객의 활동 여부의 경우
활동 고객은 이탈에 비해 잔류가 약 3배 많고,
비 활동 고객은 이탈에 비해 잔류가 6배 많다.



<그림 3-4> HasCrCard 변수 이탈여부 빈도 분석


신용카드 소유여부의 경우
카드가 있는 고객의
이탈에 비해 잔류가 약 4배 높고,
카드가 없는 고객의 경우 역시
이탈에 비해 잔류가 약 4배 높다.

기초 통계량 분석



<그림 3-5> Age_Category 변수 이탈여부 기초 통계량 분석



연령의 경우 30대가 월등히 많고,
이탈 고객의 경우 40대가 가장 많이 분포해 있다.





<그림 3-6> NumOfProduct 변수 이탈여부 기초 통계량 분석

상품의 수로는 대부분 고객이 상품을 1개 또는 2개를 이용하고,
상품을 다량 이용하는 사람은 오히려 이탈 고객의 비율이 많은 것을 알 수 있다.

기초 통계량 분석



<그림 3-7> CreditScore 변수 이탈여부 기초 통계량 분석




<그림 3-8> Age 변수 이탈여부 기초 통계량 분석

<표 3-1> CreditScore, Age 변수 이탈여부 기초 통계량 분석


	CreditScore (신용 점수)	Age (나이)
count	10000	10000
mean	650	38.92
std	96.65	10.49
min	350	18
25%	584	32
50%	652	37
75%	718	44
max	850	92

- 신용점수의 경우 이탈고객과 잔류고객의 비율이 비슷한 양상을 띄는 것을 볼 수 있다.
- 연령의 경우 이탈고객의 나이가 잔류 고객의 나이보다 전체적으로는 조금 더 높은 것을 볼 수 있다.

기초 통계량 분석



<그림 3-9> Tenure 변수 이탈여부 기초 통계량 분석




<그림 3-10> Balance 변수 이탈여부 기초 통계량 분석

<표 3-2> Tenure, Balance 변수 이탈여부 기초 통계량 분석

	Tenure (고객이 은행과 함께한 연도 수)	Balance (잔고)
count	10000	10000
mean	5.01	76485.89
std	2.89	62397.41
min	0	0
25%	3	0
50%	5	97198.54
75%	7	127644.24
max	10	250898.09

- 이탈고객의 경우 거래 이용 기간이 조금 더 넓은 형태로 분포하는 것을 볼 수 있다. 또한 이탈과 잔류고객의 중앙값이 비슷함을 알 수 있다.
- 계좌 잔고의 경우 잔류 고객의 경우 더 다양하게 분포되는 것을 볼 수 있다. 그에 반해 이탈 고객의 잔고가 조금 더 높은 모습을 볼 수 있다.

기초 통계량 분석



<그림 3-11> EstimatedSalary 변수 이탈여부 기초 통계량 분석


<표 3-3> EstimatedSalary 변수 이탈여부 기초 통계량 분석

EstimatedSalary (추정된 급여)	
count	10000
mean	100090.24
std	57510.49
min	11.58
25%	51002.11
50%	100193.92
75%	149388.25
max	199992.48

- 추정급여의 경우 잔류고객과 이탈 고객 둘 다 큰 차이가 없음을 볼 수 있다.

SMOTE

Synthetic Minority Oversampling Technique



<그림 3-12> Smote 기법 설명³⁾

KNN 알고리즘을 기반으로 적은 데이터 셋에 있는 데이터와 K개 이웃들의 차이를
일정 값으로 만들어서 기존 데이터와 약간 차이가 나는 새로운 데이터들을 증식 시키는 방법
다만, 너무 고차원의 데이터이면 잘못된 데이터가 만들어질 수도 있다.

SMOTE 적용 전후비교

<표 3-4> 의사결정나무 SMOTE 기법 적용 전의 정오분류표

	Predicted_negative	Predicted_positive
Actual_negative	2265	117
Actual_positive	366	252

결정 트리 예측 정확도=0.8390
 $= (2265 + 252) / (2265 + 117 + 366 + 252)$

결정 트리 예측 민감도=0.4078
 $= 252 / (366 + 252)$

결정 트리 예측 특이도=0.9590
 $= 2265 / (2265 + 117)$

<표 3-4>은 Smote 기법 적용 전의 의사결정나무 기법의 예측을 나타내는 정오분류표이다. 표에서 볼 수 있듯이 의사결정나무 분석의 전체 분류 정확도는 83.90%, 실제 이탈고객을 이탈고객으로 예측하는 민감도는 40.78%, 실제 잔류 고객을 예측하는 특이도는 95.90%를 나타낸다.

<표 3-5> 의사결정나무 SMOTE 기법 적용 후의 정오분류표

	Predicted_negative	Predicted_positive
Actual_negative	1847	535
Actual_positive	240	378

결정 트리 예측 정확도=0.7417
 $= (1847 + 378) / (1847 + 535 + 240 + 378)$

결정 트리 예측 민감도=0.6117
 $= 378 / (240 + 378)$

결정 트리 예측 특이도=0.7754
 $= 1847 / (1847 + 535)$

<표 3-5>은 Smote 기법 적용 후의 의사결정나무 기법의 예측을 나타내는 정오분류표이다. 표에서 볼 수 있듯이 Smote 기법 적용 후의 의사결정나무 분석 결과는 Smote 기법 적용 전보다 전체적으로 조금 떨어진 것을 볼 수 있다. 전체 분류 정확도는 74.17%, 실제 이탈고객을 이탈고객으로 예측하는 민감도는 61.17%, 실제 잔류 고객을 예측하는 특이도는 77.54%를 나타낸다.

의사결정나무

<표 3-6> 의사결정나무 정지규칙 설명

정지규칙

분리정지 (Maximum tree depth)	10
부모마디의 관측 수 제한 (Minimum Number of Case for parent)	32
자식마디의 관측 수 제한 (Minimum Number of Case for child)	2

변수

IsActiveMember (고객의 활동 여부)
NumOfProducts (상품의 수)
Gender (성별)
Age_Category (나이)
Balance (잔고)
EstimatedSalary (추정된 급여)
CreditScore (신용 점수)
Tenure (고객이 은행과 함께한 연도의 수)
HasCrCard (카드 소유 여부)

<표 3-7> 의사결정나무 독립변수

<표3-7>의 변수들이 해당 은행 고객의 이탈에 영향을 주는지 알아보기 위해

의사결정나무를 사용하였고 본 연구에서는 새로운 자료에 적용할 때 예측 오차를 줄이기 위하여 <표 3-6>과 같은 정지규칙이 제시되었다.¹⁾

전체적인 나무의 최대 깊이(Maximum tree depth)는 10, 부모마디의 관측 수 제한(Minimum Number of Case for parent)은 32, 자식마디의 관측 수 제한(Minimum Number of Case for child)은 2로 설정하였다.²⁾


나무 깊이는 의사결정나무의 가지를 이루는 가지의 수이며, 부모마디의 관측 수 제한은, 분기를 하기 위한 부모 마디의 최소 관측 수이고, 자식마디의 관측 수 제한은 부모마디의 관측수가 32이상이라도 자식마디의 한 쪽 관측 수가 2가 되지 않으면 분리하지 않는다는 의미이다.

1) 배정수, 「의사결정나무 분석 기법을 활용한 고등학생 진로결정수준 및 진로준비행동 결정요인 우선순위 탐구」, 순천향대학교 대학교 박사학위논문, 2014, 39~40쪽

2) 황지수, 「의사결정나무분석방법을 이용한 방한 일본인 쇼핑관광객의 상품구매행동의 특성에 관한 연구」, 세종대학교 대학원 석사학위논문, 2004, 77쪽

의사결정나무

<그림 3-13> 의사결정나무 결과 분류 결과표



의사결정나무

<표 3-8> 의사결정나무 정오분류표

	Predicted_negative	Predicted_positive
Actual_negative	1847	535
Actual_positive	240	378

결정 트리 예측 정확도=0.7417
 $= (1847 + 378) / (1847 + 535 + 240 + 378)$


결정 트리 예측 민감도=0.6117
 $= 378 / (240 + 378)$

결정 트리 예측 특이도=0.7754
 $= 1847 / (1847 + 535)$


<표 3-8>은 의사결정나무 기법의 예측을 나타내는 정오분류표이다. 표에서 볼 수 있듯이 의사결정나무 분석의 전체 분류 정확도는 74.17%, 실제 이탈고객을 이탈고객으로 예측하는 민감도는 61.17%, 실제 잔류 고객을 예측하는 특이도는 77.54%를 나타낸다.

의사결정나무

<그림 3-14> 의사결정나무 결과 변수 중요도



<그림 3-15> 의사결정나무 결과 ROC Curve



<표 3-9> 의사결정나무 변수 중요도

변수	중요도
IsActiveMember (고객의 활동 여부)	0.2675
NumOfProducts (상품의 수)	0.1846
Gender (성별)	0.1499
Age_Category (나이)	0.1425
Balance (잔고)	0.0898
EstimatedSalary (추정된 급여)	0.0809
CreditScore (신용 점수)	0.0412
Tenure (고객이 은행과 함께한 연도의 수)	0.0234
HasCrCard (카드 소유 여부)	0.0203

본 연구의 의사결정나무모형 적합도를 알아보기 위해 ROC Curve 검증 결과는 <그림 3-14>과 같다. ROC Curve에서 아래의 면적이 0.77로 나타나 위 모형은 본 연구에 적합하다고 할 수 있다. 모형의 변수 중요도의 수치는 <표 3-9>에서 확인 할 수 있다.⁴⁾

4) 김수진, 김보영 「로지스틱 회귀분석과 의사결정나무 분석을 이용한 일 대도시 주민의 우울 예측요인 비교 연구」, 한국콘텐츠학회 논문지, 2013년, 6쪽


실제적 해석

<그림 3-13>는 의사결정나무 기법에 의해 도출된 분석결과이다.

<그림 3-13>에서 볼 수 있듯이 은행 고객 이탈의 가장 주요한 원인은 고객의 활동 여부였음을 알 수 있고,
그 다음으로는 상품의 개수, 그리고 성별이 뒤 따라옴을 알 수 있다.

자세한 분석 내용은 다음과 같다.

실제적 해석



고객의 활동여부를 기준으로 분기하였을 때


휴면 고객 - 비 이탈 : 이탈 = 0.54 : 1.00

활동중인 고객 - 비 이탈 : 이탈 = 3.00 : 1.00

중요도가 26%인 고객의 활동여부를 기준으로 분기를 하게 되면 휴면:활동의 비율이 2.69:1.00으로 나누어지게 된다.

휴면고객, 활동중인 고객 내의 이탈여부의 비율은 각각 0.54:1.00과 3.00:1.00으로 분기되어 진다.

실제적 해석



성별을 기준으로 분기하였을 때


남성 - 비 이탈 : 이탈 = 0.30 : 1.00

여성 - 비 이탈 : 이탈 = 1.39 : 1.00

중요도가 15%인 성별을 기준으로 분기를 하게 되면 남성:여성의 비율이 2.14:1.00으로 나누어지게 된다.

남성과 여성 고객 내의 이탈여부의 비율은 각각 0.30:1.00과 1.39:1.00으로 분기되어 진다.

실제적 해석



상품의 수를 기준으로 분기하였을 때


상품의 수 1개 - 비 이탈 : 이탈 = 0.16 : 1.00

상품의 수 2개 이상 - 비 이탈 : 이탈 = 0.81 : 1.00

중요도가 18%인 상품의 수를 기준으로 분기를 하게 되면 1개 이하:2개 이상의 비율이 2.39:1.00으로 나누어지게 된다.

상품의 수가 1개 이하, 2개 이상의 고객 내의 이탈여부 비율은 각각 0.16:1.00과 0.81:1.00으로 분기된다.

실제적 해석



나이를 기준으로 분기하였을 때

30대 이하 - 비 이탈 : 이탈 = 2.93 : 1

40대 이상 - 비 이탈 : 이탈 = 0.55 : 1

중요도가 14%인 나이를 기준으로 분기를 하게 되면 30대 이하:40대 이상의 비율이 1.36:1.00으로 나누어지게 된다.

나이가 30대 이하, 40대 이상인 고객 내의 이탈여부 비율은 각각 2.93:1.00과 0.55:1.00으로 분기된다.

실제적 해석 및 해결 방안

1. 40대 이상 고객의 이탈

- ▶ 고연령층의 고객을 위한 맞춤형 프리미엄 혜택 제공

2. 휴면 고객의 이탈

- ▶ 군적금을 벤치마킹한 기존의 상품과는 차별화된 기간약정의 예금 및 적금 상품 제공

로지스틱 회귀분석

<표 3-10> 로지스틱 회귀분석의 정오분류표

	Predicted_negative	Predicted_positive
Actual_negative	1693	668
Actual_positive	210	429

회귀 분석 예측 정확도=0.7073
 $= (1693 + 429) / (1693 + 668 + 210 + 429)$


회귀 분석 예측 민감도=0.6714
 $= 429 / (210 + 429)$

회귀 분석 예측 특이도=0.7171
 $= 1693 / (1693 + 668)$


<표 3-10>은 로지스틱 회귀분석 기법의 예측을 나타내는 정오분류표이다. 표에서 볼 수 있듯이 로지스틱 회귀분석의 전체 분류 정확도는 70.73%, 실제 이탈고객을 이탈고객으로 예측하는 민감도는 67.14%, 실제 잔류 고객을 예측하는 특이도는 71.71%를 나타낸다.

로지스틱 회귀분석

<그림 3-16> 로지스틱 회귀분석 회귀계수



<그림 3-17> 로지스틱 회귀분석 결과 ROC Curve



<표 3-11> 로지스틱 회귀분석 회귀계수

변수	중요도
Age_Category (나이)	0.6528
Balance (잔고)	0.3045
EstimatedSalary (추정된 급여)	0.0219
Tenure (고객이 은행과 함께한 연도의 수)	-0.0666
CreditScore (신용 점수)	-0.0740
HasCrCard (카드 소유 여부)	-0.1266
NumOfProducts (상품의 수)	-0.3324
Gender (성별)	-0.8106
IsActiveMember (고객의 활동 여부)	-1.1758

본 연구의 로지스틱 회귀모형 적합도를 알아보기 위해 ROC Curve 검증 결과는 <그림 3-16>과 같다. ROC Curve에서 아래의 면적이 0.75로 나타나 위 모형은 본 연구에 적합하다고 할 수 있다. 모형의 회귀계수는 <표 3-11>에서 확인 할 수 있다.

로지스틱 회귀분석(변수 선택)

<표 3-12> 통계적으로 유의미한 변수 선택을 위한 로지스틱 회귀분석

Logit Regression Results						
Dep. Variable:	Exited	No. Observations:	10000			
Model:	Logit	Df Residuals:	9990			
Method:	MLE	Df Model:	9			
Date:	Thu, 10 Dec 2020	Pseudo R-squ.:	0.1342			
Time:	19:49:42	Log-Likelihood:	-4376.6			
Converged:	True	LL-Null:	-5054.9			
Covariance Type:	nonrobust	LLR p-value:	1.833e-286			
	coef	std err	z	P> z	[0.025	0.975]
Intercept	-3.0541	0.128	-23.863	0.000	-3.305	-2.803
Balance	0.3149	0.029	10.992	0.000***	0.259	0.371
EstimatedSalary	0.0246	0.027	0.914	0.361	-0.028	0.077
Tenure	-0.0420	0.027	-1.571	0.116	-0.094	0.010
HasCrCard	-0.0264	0.059	-0.451	0.652	-0.141	0.088
NumOfProducts	-0.0406	0.046	-0.878	0.380	-0.131	0.050
CreditScore	-0.0617	0.027	-2.305	0.021*	-0.114	-0.009
Gender	-0.5494	0.054	-10.209	0.000***	-0.655	-0.444
IsActiveMember	-1.0641	0.057	-18.713	0.000***	-1.176	-0.953
Age_Category	0.6858	0.025	27.844	0.000***	0.638	0.734

*p<0.05, **p<0.01, ***p<0.001

변수선택은 목표변수에 대해 여러 설명변수들이 주어졌을 때
목표변수의 값에 영향력이 있는 설명변수들을 선택하는 것이다.

변수선택이 필요한 이유는 영향력이 없는 변수들이 모형에
포함되면 설명변수와 목표변수 간에 올바른 관계를 알기가

어려우며 올바른 모형에 비해 예측오차가 증가할 수 있기 때문이다. ⁵⁾

분석결과를 살펴보면 통계적으로 의미가 있는 변인들은

'Balance' (잔고), 'CreditScore' (신용 점수), 'Gender' (성별),

'IsActiveMember' (고객의 활동여부), 'Age_Category' (나이) 5가지로 나타났지만,

이 5가지 변수를 선택하는 것이 아닌 분석에 있어 통계적으로 유의미한

결과를 보일 것 같은 변수 'Balance' (잔고), 'NumOfProducts' (상품의 수),

'Gender' (성별), 'IsActiveMember' (고객의 활동여부),

'Tenure' (고객이 은행과 함께한 연도 수), 'Age_Category' (나이) 6가지를 선택하였다.

선택한 변수:

'Balance' (잔고), 'NumOfProducts' (상품의 수),

'Gender' (성별), 'IsActiveMember' (고객의 활동여부),

'Tenure' (고객이 은행과 함께한 연도 수), 'Age_Category' (나이)

5) 오세웅, 「로지스틱 회귀모형과 랜덤포레스트를 혼합한 변수선택법에 기반하여 의사결정나무를 이용한 외래 관광객 만족도 분석」, 한양대학교 대학원 석사학위논문, 2017년. 17쪽

로지스틱 회귀분석(변수 선택)

<표 3-13> 로지스틱 회귀분석의 정오분류표

	Predicted_negative	Predicted_positive
Actual_negative	1670	712
Actual_positive	210	408

회귀 분석 예측 정확도=0.6927
 $= (1670 + 408) / (1670 + 712 + 210 + 408)$


회귀 분석 예측 민감도=0.6602
 $= 408 / (210 + 408)$

회귀 분석 예측 특이도=0.7011
 $= 1670 / (1670 + 712)$

<표 3-13>은 변수 선택 후의 로지스틱 회귀분석 기법의 예측을 나타내는 정오분류표이다. 표에서 볼 수 있듯이 변수 선택 후의 로지스틱 회귀분석의 전체 분류 정확도는 69.27%, 실제 이탈고객을 이탈고객으로 예측하는 민감도는 66.02%, 실제 잔류 고객을 예측하는 특이도는 70.11%를 나타낸다.

로지스틱 회귀분석(변수 선택)


<그림 3-18> 변수 선택 후의 로지스틱 회귀분석 회귀계수



<표 3-14> 변수 선택 후의 로지스틱 회귀계수

변수	중요도
Age_Category (나이)	0.7481
Balance (잔고)	0.3176
Tenure (고객이 은행과 함께한 연도 수)	-0.0012
NumOfProducts (상품의 수)	-0.2087
Gender (성별)	-0.6588
IsActiveMember (고객의 활동 여부)	-1.0343

<그림 3-19> 변수 선택 후의 로지스틱 회귀분석 결과 ROC Curve



본 연구의 로지스틱 회귀모형 적합도를 알아보기 위해 ROC Curve 검증 결과는 <그림 3-19>과 같다. ROC Curve에서 아래의 면적이 0.73정도로 나타나 위 모형은 본 연구에 적합하다고 할 수 있다. 모형의 회귀 계수의 수치는 <표 3-14>에서 확인 할 수 있다.

로지스틱 회귀분석(변수 선택)

- 변수선택을 진행하였더니 예상과는 다르게 오히려 정확도 및 auc-score 등이 전체적으로 하락한 모습을 볼 수 있다. 따라서 로지스틱 회귀모형에서의 모형은 변수선택을 하기 이전인 전체 변수를 가지고 예측한 모형을 사용하기로 결정하였다.

실제적 해석

- 따라서 로지스틱 회귀 분석 결과 고객이 이탈한 오즈비는 다음과 같다.

$$\begin{aligned} \text{Odds} = & \exp(-0.9299 + 0.6527 * \text{Age_Category} + 0.3045 * \text{Balance} \\ & + 0.0219 * \text{EstimatedSalary} - 0.0665 * \text{Tenure} - 0.0739 * \text{CreditScore} \\ & - 0.1265 * \text{HasCrCard} - 0.3323 * \text{NumOfProducts} \\ & - 0.8106 * \text{Gender} - 1.1757 * \text{IsActiveMember}) \end{aligned}$$

실제적 해석

- 고객이 이탈할 확률은 앞서 언급한 오즈비로 계산한다.

$$\frac{odds}{1 + odds}$$

- 이탈할 확률에서 가장 큰 요소인 고객의 활동여부는 $\exp(-1.1758)=0.3085$ 로 휴면고객이 활동고객이 될 경우 이탈율이 0.3085배 감소한다. 즉, 휴면고객의 이탈율이 활동고객보다 70% 가량 이탈할 확률이 높다.
- 또한 성별을 제외하고 다음으로 이탈 확률에 큰 영향을 미치는 나이대를 살펴보면 $\exp(0.6528)=1.9209$ 나이가 한 단위(10살 단위) 증가 할 때 마다 고객의 이탈율이 1.9209배만큼 증가한다. 다른 말로 하면 나이대가 한 단위 증가하면 고객의 이탈율이 92% 가량 증가한다.

모형평가 및 비교

<표 3-15> 의사결정나무의 회귀분석의 정오분류표

	Predicted_negative	Predicted_positive
Actual_negative	1847	535
Actual_positive	240	378

- 결정 트리 예측 정확도=0.7417
- 결정 트리 예측 민감도=0.6117
- 결정 트리 예측 특이도=0.7754
- ROC-AUC: 0.7706

<표 3-16> 로지스틱 회귀분석의 정오분류표

	Predicted_negative	Predicted_positive
Actual_negative	1693	668
Actual_positive	210	429

- 로지스틱 회귀분석 예측 정확도=0.7073
- 로지스틱 회귀분석 예측 민감도=0.6714
- 로지스틱 회귀분석 예측 특이도=0.7532
- ROC-AUC: 0.7532

고객의 이탈을 막기 위해 만든 대책 모델로는 의사결정나무가 더 좋은 것을 확인하였다.


다만 임계치를 확인하며 **cut-off 포인트를 확인**하여 더 좋은 모델을 선정하였다.

의사결정나무

<표 3-17> 의사결정나무 최적의 임계값 찾기 위한 계산

임계값	정확도	민감도	특이도
0.10	0.5367	0.8851	0.4463
0.15	0.6020	0.8398	0.5430
0.20	0.6247	0.8107	0.5764
0.25	0.6463	0.7896	0.6092
0.30	0.6707	0.7427	0.6520
0.35	0.6890	0.7104	0.6835
0.40	0.7153	0.6780	0.7250
0.45	0.7150	0.6586	0.7296
0.50	0.7417	0.6117	0.7754

기계적으로 [민감도-(1-특이도)]의 값이 가장 큰 값을 계산하여 나온 0.40과 연구자의 입장에서 봤을 때, 정확도와 민감도 그리고 특이도의 균형이 잘 잡혔다고 생각한 cut-off point인 0.40이 일치하여 0.40을 최적의 cut-off 포인트로 결정



- Cut-off point = 0.40
- 결정 트리 예측 정확도=0.7417
- 결정 트리 예측 민감도=0.6117
- 결정 트리 예측 특이도=0.7754

새로운 정오분류표

<표 3-18> cut-off point를 0.40으로 했을 때의 의사결정나무 정오분류표

	Predicted_negative	Predicted_positive
Actual_negative	1727	655
Actual_positive	199	419

결정 트리 예측 정확도=0.7153
 $= (1727 + 419) / (1727 + 655 + 199 + 419)$

결정 트리 예측 민감도=0.6780
 $= 419 / (199 + 419)$

결정 트리 예측 특이도=0.7250
 $= 1727 / (1727 + 655)$

<표 3-18>은 cut-off point를 0.40으로 설정하였을 때의 의사결정나무 기법의 예측을 나타내는 정오분류표이다. 표에서 볼 수 있듯이 cut-off point를 0.40으로 설정하였을 때의 의사결정나무 분석의 전체 분류 정확도는 71.53%, 실제 이탈고객을 이탈고객으로 예측하는 민감도는 67.80%, 실제 잔류 고객을 예측하는 특이도는 72.50%를 나타낸다.

회귀분석 *cut-off point*


<표 3-19> 회귀분석 최적의 임계값 찾기 위한 계산

임계값	정확도	민감도	특이도
0.10	0.2457	0.9969	0.0424
0.15	0.3117	0.9781	0.1313
0.20	0.3777	0.9515	0.2224
0.25	0.4487	0.9233	0.3202
0.30	0.5053	0.8826	0.4032
0.35	0.5583	0.8263	0.4858
0.40	0.6067	0.7778	0.5604
0.45	0.6567	0.7246	0.6383
0.50	0.7073	0.6714	0.7171

기계적으로 계산한 0.48과 연구자가 생각한 0.50의 cut-off point에서 정확도, 민감도, 특이도의 값이 다르지 않으므로 최적의 cut-off point를 0.50으로 결정

0.48

<그림 3-21> cut-of point를 0.48로 설정한 회귀분석 결과 ROC Curve



- Cut-off point = 0.48
- 회귀 분석 예측 정확도=0.7073
- 회귀 분석 예측 민감도=0.6714
- 회귀 분석 예측 특이도=0.7171

새로운 정오분류표

<표 3-20> cut-off point를 0.50으로 설정한 로지스틱 회귀분석 정오분류표

	Predicted_negative	Predicted_positive	<=기존과 동일
Actual_negative	1693	668	
Actual_positive	210	429	

회귀 분석 예측 정확도=0.7073
 $= (1693 + 429) / (1693 + 668 + 210 + 429)$


회귀 분석 예측 민감도=0.6714
 $= 429 / (210 + 429)$

회귀 분석 예측 특이도=0.7171
 $= 1693 / (1693 + 668)$

<표 3-20>은 cut-off point를 0.50으로 설정하였을 때의 로지스틱 회귀분석 기법의 예측을 나타내는 정오분류표이다. 표에서 볼 수 있듯이 cut-off point를 0.50으로 설정하였을 때의 로지스틱 회귀분석의 전체 분류 정확도는 70.73%, 실제 이탈고객을 이탈고객으로 예측하는 민감도는 67.14%, 실제 잔류 고객을 예측하는 특이도는 71.71%를 나타낸다.

최적 모형

- Cut-off point를 0.40으로 정한 의사결정나무
- 정확도가 0.7을 넘기며, 특이도와 민감도의 균형이 적절함



<그림 3-22> cut-off point를 0.40으로 설정한 로지스틱 회귀분석 결과 변수 중요도

- 나이대가 40대 이상인 고객의 이탈율이 높음
- 상품의 수가 많은 사람일 수록 오히려 비율상으로는 이탈율이 높음
- 휴면고객의 경우 비 휴면 고객보다 이탈율이 높음

앞서 제시한 상품들인 균적금을 벤치마킹한 상품과 고연령대의 프리미엄 제품을 개발 및 제공하는 것과 더불어 여러가지 상품을 이용하는 고객일수록 오히려 이탈하는 비율이 많았으므로, 이를 개선하기 위하여 상품을 여러가지 이용할 수 록 추가적인 혜택을 제공하거나 혹은 다른 상품들과 시너지 효과를 줄 수 있도록 하는 제도를 만들어볼 수 있다.

참고문헌

논문

- [1] 황진수, 「의사결정나무분석방법을 이용한 방한 일본인 쇼핑관광객의 상품구매행동의 특성에 관한 연구」, 세종대학교 대학원 석사학위논문, 2004년.
- [2] 배정수, 「의사결정나무 분석 기법을 활용한 고등학생 진로결정수준 및 진로준비행동 결정요인 우선순위 탐구」, 순천향대학교 대학교 박사학위논문, 2014년.
- [3] 김수진, 김보영, 「로지스틱 회귀분석과 의사결정나무 분석을 이용한 일 대도시 주민의 우울 예측요인 비교 연구」, 한국콘텐츠학회 논문지, 2013년.
- [4] 오세웅, 「로지스틱 회귀모형과 랜덤포레스트를 혼합한 변수선택법에 기반하여 의사결정나무를 이용한 외래관광객 만족도 분석」, 한양대학교 대학원 석사학위논문, 2017년.

기사

- [5] 이동은, “은행권, 시니어 고객 확보 위한 마케팅 강화”, 『미디어펜』, 2020년 9월 28일.
- [6] 김경찬, “20대와 점점 확대하는 시중은행, ‘마케팅 경쟁’ 치열”, 『한국금융』, 2020년 10월 26일.
- [7] 박진영, “[밀레니엄금융]은행권, 1020세대 고객 잡기 마케팅 ‘열전’”, 『시사오늘』, 2020년 6월 19일.