

A dimension reduction assisted credit scoring method for big data with categorical features

Tatjana Miljkovic and Pei Wang

2조 : 김지원, 성태현, 심유림

CONTENT

01 | 연구 배경 및 필요성

02 | MMRN-based
DCOV-SDR

03 | 데이터설명

04 | 사례연구

05 | 사례연구 결과 해석


06 | 실제 데이터 적용

01. 연구배경 및 필요성

신용평가 (Credit Scoring)의 중요성



신용평가 모델로 고객의 부도 여부를 예측하고,
고객을 저·중·고 위험군으로 나눔




신용평가의 정확도가 소폭만 향상되어도 오분류율 감소
→ 금융 손실 감소 효과가 매우 큼

⇒ 신용평가 모델의 정확성은 금융기관의 수익을 극대화하면서
위험 노출을 효과적으로 관리하기 위한 핵심 관심사가 됨

01. 연구배경 및 필요성

신용평가 프로세스(DRA-CS 순서도)

DRA-CS(Dimension Reduction Assited Credit Scoring)



01. 연구배경 및 필요성

신용평가 데이터 특징

- 범주형 변수 비중 높음
- 변수 증가 시 다중공선성 높아짐
- 비선형/비정규 분포 비율 높아짐
- 결측 및 이상치 많음

PCA의 구조적 한계

- Y 정보 반영 하지 못함, X의 분산만 고려
- 범주형 변수에서 불안정
- 고차원에서 노이즈를 크게 잡아 과적합 발생할 수 있음
- 비선형 구조를 반영하지 못함

What is lacking?

최신 SDR 차원축소 기법의 부재

- 기존 SDR 기법은 정규성 / 선형 구조 가정이 있어 실제 신용평가 데이터에 적합하지 않음
- 기존 방법(PCA, LASSO, Stepwise)의 제한
- 고차원 / 범주형 데이터 특성 반영 부족

*SDR : Sufficient Dimension Reduction

➤ Supervised + 비선형, 범주형 처리 가능 + 정보 손실 최소화를 만족하는 차원축소 기법 필요

02. MMRN-based DCOV-SDR

DCOV (Distance Covariance) 란?

- 두 랜덤벡터 X, Y 사이의 의존 강도를 측정하는 지표
- 비선형 / 비정규 / 범주형 / 혼합형에서도 성립
- 거리 기반이라 모델 가정 없음 (model-free)


DCOV-SDR:

- $dCov$ 를 이용해 Y 와 가장 강하게 의존하는 '중심 부분 공간(central subspace)'를 찾음
- β 는 d 개의 축(basis)으로 구성된 행렬이며, 이 β 가 X 를 Y 와 가장 잘 연결하는 방향 집합을 의미
- $\beta^T X$ 로 투영된 고차원에서도 핵심 정보를 유지하면서 정보손실 최소화 가능

02. MMRN-based DCOV-SDR

목적함수

$$\nu_n^2(\beta^T X, Y) := \frac{1}{n^2} \sum_{k,l=1}^n a_{kl}(\beta) B_{kl}, \quad s.t. \quad \beta^T \hat{\Sigma} \beta = I_d$$



$$\max_{\beta} \nu_n^2(\beta^T X, Y)$$

$$a_{kl}(\beta) = \|\beta^T X_k - \beta^T X_l\|_2 \quad B_{kl} = b_{kl} - \bar{b}_{\cdot k} - \bar{b}_{\cdot l} + \bar{b}_{\cdot \cdot}$$

DCOV-SDR의 한계점

- 목적함수가 non-convex & non-smooth 구조를 가짐
- 거리 기반 항이 존재하여 gradient descent 또는 convex optimization으로는 안정적인 해를 찾기 어려움
- β 가 Stiefel manifold 제약($\beta^T \Sigma \beta = I$)을 가져 일반 최적화 적용 불가
- dCov 계산의 경우 표본 쌍의 거리를 필요로 함 → 신용평가 데이터에서 계산량이 증가해 실용성 ↓ 가능성
- 차원 d를 추정해야하는 절차 필요

➤ DCOV-SDR을 대규모 고차원 데이터에 안정적으로 적용할 수 있는 MMRN 기반의 최적화 알고리즘 개발 필요

02. MMRN-based DCOV-SDR

MM Algorithm 목적함수를 국소적으로 근사하는 surrogate function를 구성하여 이를 최대화하여 반복적으로 최적해 탐색

1) 교란항(perturbation term) 추가

- $a_{kl}(\beta)$ 에 작은 상수 $\varepsilon > 0$ 를 넣어서 '너무 뽕족한' 부분을 완화하여 미분 가능에 가깝게 만듦

2) Supporting hyperplane Inequality 활용

- 원래 목적함수 위에 항상 아래에 깔리는 (majorization) 더 단순한 함수 = 대리 함수(surrogate function)를 만듦
- 이 대리함수는 미분이 가능하고 계산이 쉬운 형태

RN (Riemannian Newton)

3) Stiefel manifold 상에서 Newton step 수행

- β 는 차원축소 방향벡터이므로 직교성 제약($\beta^T \Sigma \beta = I$)을 만족해야 함
- 이런 직교 제약을 가진 공간이 바로 Stiefel manifold → Riemannian Newton 사용

02. MMRN-based DCOV-SDR

PCA vs MD-SDR

항목	PCA	MD-SDR
축 찾는 기준	X의 분산	X-Y 의존성(dCov)
supervised?	X만 사용(unsupervised)	Y 사용(supervised)
범주형	취약	강함
비선형	포착 불가	포착 가능
정보 손실	큼	작음
신용평가 적합성	낮음	매우 높음

03. 데이터 설명

- R package CASdatasets에 포함된 German Credit Data (1,000 명 * 21개 변수)
- 변수 구성
 - 범주형 15개, 수치형 6개
 - 종속 변수: Class (신용 우량/불량)
- 사용 목적
 - MD-SDR 차원 축소 시연 → 사례연구 1
 - 신용점수 평가모형 구축(Logistic + Scorecard) → 사례연구 2

04. 사례연구 : Dimension Reduction

- PCA와 MD-SDR 두가지 차원축소 기법을 비교하여, 어떤 방법이 더 적은 차원으로 더 많은 정보를 유지할 수 있는지, 그리고 그 결과 예측력이 어떤 차이를 보이는지 확인

PCA의 차원 선택 기준
CPVE

vs

MD-SDR의 차원 선택 기준
Subspace Distance


- Y가 binary(이진)이기 때문에 아래 식의 log-odds 모델을 사용하여 비교

$$\log \frac{P(Y = 1)}{P(Y = 0)} = \gamma_0 + \gamma_1 X_1^* + \cdots + \gamma_{\hat{d}} X_{\hat{d}}^*$$


$\nu_0, \nu_1, \cdots, \nu_d$: 회귀 계수

$X_1^*, \cdots, X_d^*$: 축소된 변수들

04. 사례연구 : Credit Scoring by the Three-step approach



04. 사례연구 : 결과해석



MD-SDR은 PCA뿐만 아니라 Stepwise 방법보다도 전반적으로 더 낮은 오분류율과 더 안정적인 리스크 분류 성능을 보였음

즉, 신용점수화 과정에서도 MD-SDR이 가장 우수한 방법

05. 우수성

- MD-SDR은 PCA/Stepwise 대비 높은 예측력 제공
- 범주형 변수에 대한 대응 능력이 우수
- MMRN 기반 MD-SDR은 수치적 불안정성을 최소화
- 실제 데이터에서도 우수한 성능 검증


06. 실제 데이터 적용 : 데이터 설명

- Kaggle Loan Approval Classification Dataset(45,000중 무작위 1000개 추출*14개변수)
- 변수 구성
 - 범주형 6개, 수치형 8개
 - 종속 변수: loan_status (대출 승인/거절)
- 전처리 과정
 - 대표성을 유지하는 선에서 1000개 랜덤 추출
 - dummy coding
- 사용 목적
 - MD-SDR 차원 축소 시연
 - 논문 재연

06. 실제 데이터 적용 : 코드 구현

1. 임의의 B에 대한 $Z=B'X$ 로 선형변환

2. distance covariance계산

3. gradient 기반 numerical optimization 

- Stiefel manifold와 같은 단순 직교 구조
- Euclidean gradient 업데이트 후 직교화
- Wen, Z., & Yin, W. (2013)


4. 축소 subspace 생성

5. 로지스틱 회귀 적합

6. 모형평가


06. 실제 데이터 적용

MD-SDR



MM-SDR에서의 최적의 $k=4$

PCA



PCA에서는 $k=2, k=4$ 로 차원을 축소

06. 실제 데이터 적용 : Confusion Matrix

MD-SDR

		Actual	
		0	1
Predicted	0	696	82
	1	47	175

PCA(2)

		Actual	
		0	1
Predicted	0	730	112
	1	43	115

PCA(4)

		Actual	
		0	1
Predicted	0	724	105
	1	49	122

06. 실제 데이터 적용 : Model Evaluation

	Accuracy	FDR	FNR	Precision	Recall	F1-score	AUC
MD-SDR	0.871	0.212	0.319	0.789	0.681	0.731	0.9202
PCA 2	0.845	0.272	0.494	0.727	0.507	0.60	0.8681
PCA 4	0.846	0.286	0.463	0.713	0.537	0.613	0.8780

감사합니다

02. MMRN-based DCOV-SDR

차원 d 결정 기준 : Subspace Distance Criterion

- 차원축소의 structural dimension d 은 사전에 알려져 있다고 가정하지만, 실제 데이터에서는 이를 추정(estimate) 필요
- Subspace Distance Method를 이용해서 원본데이터와 부트스트랩 데이터 간 subspace distance를 최소화하는 k를 선택

$$\delta_{\kappa}(\hat{S}_{\kappa}, \hat{S}_{\kappa}^b) = \left\| P\hat{S}_{\kappa} - P\hat{S}_{\kappa}^b \right\|$$

$\hat{S}_{\kappa}$: k차원이라고 가정했을 때, 원본 데이터에서 얻은 부분 공간
 $\hat{S}_{\kappa}^b$: k차원이라고 가정했을 때, 부트스트랩 데이터에서 얻은 부분 공간

- 최종 차원은 다음과 같이 결정

$$\hat{d}_{MMRN} = \underset{\kappa}{\operatorname{argmin}} \delta_{\kappa}(\hat{S}_{\kappa}, \hat{S}_{\kappa}^b)$$

