

A Dimension Reduction Assisted Credit Scoring Method for Big Data with Categorical Features

Tatjana Miljkovic and Pei Wang(2025)

김지원(2025712683), 성태현(2025713759), 심유림(2025710053)

1. 연구 배경 및 필요성

1.1 신용평가의 중요성

최근 금융기관들은 신용평가(Credit Scoring) 모델을 핵심 도구로 활용하여 소비자 대출의 부도 가능성을 예측하고 대출 신청자를 위험 등급별로 분류함으로써 리스크 관리와 수익성 제고에 중요한 역할을 수행해 왔다. 대출 규모가 큰 소비자 금융시장의 특성상 신용평가 모델의 성능이 조금만 개선되더라도 오분류율 감소를 통해 금융 손실을 크게 줄일 수 있기 때문에, 정확한 신용위험 예측은 금융기관의 안정성과 소비자의 재무건전성을 동시에 지탱하는 필수 요소라 할 수 있다. 한편, 최근 신용평가 환경은 데이터 규모와 다양성이 급격히 증가하면서 과거보다 훨씬 복잡해지고 있으며, 직업·거주형태·대출 목적과 같은 범주형 변수부터 거래 패턴, 계좌 정보, 과거 상환 이력 등 다양한 정보가 고차원 데이터 형태로 축적되고 있다. 더불어 Basel II는 금융기관이 자체 고객 데이터를 기반으로 내부 신용평가 시스템을 구축할 것을 요구하고 있어, 기관마다 상이한 고객 특성과 산업 구조를 반영한 맞춤형 모델 개발이 필수적이다. 이러한 배경에서 금융기관은 데이터 기반 시대의 경쟁력을 유지하기 위해 증가하는 데이터의 복잡성과 규모를 효과적으로 활용할 수 있는 정교한 통계·머신러닝 기반 신용평가 기법을 지속적으로 도입할 필요가 있다.

1.2 신용평가 데이터의 특성과 기존 방법론의 한계

실제 금융기관이 활용하는 신용평가 데이터에는 직업, 거주 형태, 대출 목적, 계좌 보유 여부, 외국인 여부와 같이 범주형 변수가 대량으로 포함되어 하나의 변수에 다수의 범주(level)가 존재하는 경우도 매우 흔하다. 이러한 변수들은 통계 모델에 직접 사용할 수 없어 더미(dummy) 형식으로 변환되어야 하며 이 과정은 데이터의 차원을 더욱 확장시키는 결과를 초래한다. 이와 더불어 대출 기간, 소득, 연령 등 연속형 변수에서도 비정규성(non-normality), 왜도(skewness), 첨도(kurtosis)가 일반적으로 관찰되며, 부도 확률이 특정 지점에서 급격히 증가하는 현상처럼 비선형성(nonlinearity)이 강하게 나타난다. 그 결과 신용평가 데이터는 고차원, 범주형, 혼합형, 비정규, 비선형 구조를 동시에 가진 매우 복잡한 데이터로 구성된다.

이러한 특성은 기존의 전통적 차원 축소 및 변수선택 방법론이 실제 신용평가 데이터에 적합하지 않다는 점을 명확히 보여준다. PCA(Principal Component Analysis)는 X의 분산을 기준으로 주성분을 찾는 unsupervised 방식이기 때문에 Y(부도 여부)와의 관계를 전혀 고려하지 않는다. 이로 인해 분산은 작지만 예측에 매우 중요한 변수들이 제거될 위험이 크며, 결과적으로 정보 손실이 크게 발생할 수 있다. 또한 PCA는 분산/공분산 거리 기반의 선형 차원 축소 방법이기 때문에 더미코딩된 범주형 변수 처리에 구조적으로 취약하며 이러한 구조적 한계는 해석 불가능한 축을 만들어내거나 잘못된 통계적 결론을 유발할 수 있다. 한편 Stepwise Regression 방식은 통계적으로 유의하지 않은 변수를 순차적으로 제거하는 과정에 크게 의존하는데, 이는 단지 표본의 특성이나 데이터의 불안정성 때문에 유의성이 낮게 나타났을 뿐 실제로는 중요한 변수일 가능성이 존재한다. 즉 중요 정보가 소실될 위험이 상존한다.

결국 신용평가 데이터에 적합한 차원축소 기법의 핵심 요건은 다음과 같은 특성을 모두 충족해야 한다.

- (1) 범주형·연속형·혼합형 데이터 처리 가능성
- (2) 비정규성·비선형성 구조 반영
- (3) 고차원 데이터에서도 정보 손실 최소화
- (4) 종속변수 Y와의 관계를 직접적으로 반영하는 supervised 차원축소
- (5) 데이터 분포 변화(population drift)에 견고한 성능 유지

그러나 기존의 PCA, Stepwise, LASSO 기반 접근법은 이러한 조건을 충족하지 못함으로써 실질적 한계를 드러내고 있다. 특히 Y-X 관계를 유지하면서 X의 차원을 최소화하는 Sufficient Dimension Reduction(SDR) 기법이 최근 통계학에서 활발히 발전했음에도 신용평가 분야에서는 거의 적용된 사례가 없다. 더욱이 Distance Covariance 기반 SDR(DCOV-SDR)처럼 비선형·비정규·범주형 데이터에서도 안정적인 성능을 발휘하는 첨단 기법조차 신용평가에서는 사실상 활용되지 못하고 있다.

따라서 신용평가 분야에서 현재 가장 부족한 것은 고차원·범주형·비선형·비정규 데이터의 복잡성을 반영하면서도, 종속변수 Y와의 관계를 직접적으로 학습할 수 있는 supervised 차원축소 기술이다. 본 연구가 제안하는 MMRN 기반 DCOV-SDR(MD-SDR)은 이러한 연구 공백을 해결하기 위한 방법으로, 신용평가 데이터의 구조적 특성과 기존 방법론의 한계를 동시에 고려하여 개발된 새로운 차원축소 접근법이다.

2. 신용평가 프로세스 (DRA-CS Framework)



[그림] 신용평가 프로세스(DRA-CS 순서도)

본 연구에서 제안하는 DRA-CS(Dimension Reduction Assisted Credit Scoring) 프레임워크는 전체 프로세스를 [차원축소 → 예측모형 → 점수화] 세 단계로 체계적으로 구조화하였다. 각 단계는 고차원·범주형 중심의 실제 신용평가 데이터를 안정적으로 처리하고, 예측 성능과 해석력을 동시에 확보하기 위한 역할을 수행한다.

2.1 DCOV 기반 차원축소(DCOV-SDR)

신용평가 데이터에서 PCA가 가지는 한계를 극복하기 위해 본 연구는 Distance Covariance(DCOV)를 기반으로 한 Sufficient Dimension Reduction(SDR) 기법을 도입하였다. DCOV는 두 랜덤벡터 X와 Y 사이의 의존성(dependence)을 측정하는 통계량으로, 이는 기존의 공분산 기반 축도와 달리, 비정규성·비선형성·범주형·혼합형 구조에서도 안정적으로 작동하며, 모델 가정을 요구하지 않는 model-free 특징을 가진다. 이러한 특성 덕분에 DCOV는 신용평가 데이터와 같은 복잡한 구조의 데이터에서 Y와 X의 관계를 포착하기에 적합하다.

DCOV의 목적은 X 를 저차원 변수 집합 $Z = \beta^T X$ 로 변환하되, 이 변환이 Y 와의 의존성을 최대한 보존하는 선형결합 β 를 찾는 것이다. 즉, 최적의 β 는 목적함수(*)의 해로 정의된다. 이 목적함수는 $\beta^T X$ 와 Y 사이의 DCOV를 최대화($\max_{\beta} \nu_n^2(\beta^T X, Y)$) 하도록 설정되며, 그 결과 β 는 Y 를 설명하는 데 필요한 최소한의 정보를 유지하는 중심 부분공간(central subspace)을 형성한다. 이를 통해 고차원 데이터에서도 정보 손실을 최소화하여 차원축소를 수행할 수 있다.

$$(*) \text{ 목적함수: } \nu_n^2(\beta^T X, Y) := \frac{1}{n^2} \sum_{k,l=1}^n a_{kl}(\beta) B_{kl}, \text{ s.t. } \beta^T \hat{\Sigma} \beta = I_d \quad (a_{kl}(\beta) = \|\beta^T X_k - \beta^T X_l\|_2^2 \quad B_{kl} = b_{kl} - \bar{b}_{\cdot k} - \bar{b}_{\cdot l} + \bar{b}_{\cdot \cdot})$$

2.2 DCOV-SDR의 한계와 MMRN 기반 DCOV-SDR

DCOV-SDR은 비선형·비정규·범주형·혼합형 데이터에서도 안정적으로 작동하는 감독형 차원축소 기법으로 신용평가 데이터의 복잡한 구조를 반영할 수 있다는 점에서 매우 이상적인 방법이다. 그러나 실제 데이터에 적용하는 데에는 여러 한계가 존재한다.

- (1) DCOV는 거리 기반 통계량으로 구성되기 때문에 목적함수에 절대값(|·|) 연산이 포함되어 있어 비미분적(non-differentiable) 형태를 띤다. 이는 gradient 기반 최적화 기법을 직접 사용할 수 없게 만드는 요인으로 작용한다.
- (2) DCOV-SDR의 목적함수는 비선형·비볼록(non-covex) 구조를 가지므로 단순한 수치 최적화 방법은 지역해(local optimum)에 빠질 가능성이 높고 계산 안정성을 보장하기 어렵다.
- (3) β 는 단순한 자유 파라미터가 아니라 Stiefel manifold($\beta^T \Sigma \beta = I$)라는 직교 제약 조건을 만족해야 하는 행렬이므로 전통적 unconstrained optimization 방식은 사용할 수 없다.
- (4) DCOV 계산은 표본 간 거리 행렬을 반복적으로 계산해야하므로 신용평가와 같이 n 과 p 가 모두 큰 환경에서는 계산량이 급격히 증가하여 실질적인 적용이 어렵다.

이와 같은 문제 때문에 DCOV-SDR은 이론적으로 탁월함에도 불구하고 실제 신용평가 데이터에 직접 적용된 사례가 거의 존재하지 않았다. 따라서 본 연구는 MMRN(Majorization-Minimization Riemannian Newton) 알고리즘을 도입하여 DCOV-SDR의 한계를 실질적으로 극복하였다.

MMRN 기반 DCOV-SDR은 MM(Majorization-Minimization) 단계와 RN(Riemannian Newton) 단계로 구성된다. 먼저 MM 단계에서는 원래의 DCOV 목적함수를 직접 최대화하는 대신, 원함수보다 항상 위에서 접하는 대리함수(surrogate function)를 구성한다. 이 surrogate 함수는 원 함수의 비미분적 부분을 매끄럽게 근사하기 위해 작은 교란항(perturbation term)을 추가하여 부드럽게 만들고, 지지 초평면 부등식(supporting hyperplane inequality)을 이용해 계산 가능하고 미분 가능한 형태로 재구성된다. 이 과정을 통해 복잡하고 비미분적인 DCOV 목적함수가 수치적 최적화에 적합한 형태로 변환된다.

다음으로 RN 단계에서는 β 가 만족해야 하는 직교 제약조건($\beta^T \Sigma \beta = I$)을 기반으로 β 를 Stiefel manifold 위에서 업데이트하는 Newton step을 수행한다. 이는 일반적인 Newton method와 달리 manifold 기하구조를 반영하여 β 를 갱신하기 때문에 제약 조건을 자연스럽게 유지하면서도 빠른 수렴 속도를 보인다. 논문에서도 SQP를 포함한 기존 제약 최적화 기법보다 25~47배 빠른 계산 속도를 보였다고 보고하고 있으며 이는 MMRN이 신용평가와 같은 대규모 데이터 환경에서 매우 실용적인 방법임을 보여준다.

결과적으로 MMRN 기반 DCOV-SDR은 DCOV-SDR의 비미분성, 비불록성, 직교 조건 제약, 높은 계산 복잡도 등 주요 제약 요소를 효과적으로 해결하며 신용평가 데이터에 실제로 적용 가능한 차원 축소 방법으로 자리매김한다. MMRN을 통해 추정된 β 는 Y와 X 사이의 의존성을 최대한 보존하는 방향을 찾는 데 효과적이며 이를 통해 고차원·범주형·비선형 구조를 가진 신용평가 데이터에서도 정보 손실을 최소화하면서 중요한 예측 정보를 추출할 수 있다. 이러한 접근은 전통적인 PCA나 Stepwise 방식과 비교했을 때 차원 축소 이후의 예측 성능을 크게 향상시키며 이후 단계인 로지스틱 회귀 및 점수카드(scorecard) 개발 과정에서도 안정성과 해석력을 보장한다.


3. 데이터 설명

본 논문에서는 제안된 MD-SDR 기법의 성능을 검증하기 위해 신용평가 분야에서 널리 활용되는 공개 신용 데이터셋을 사용하였다. 이 데이터는 총 1,000명의 대출 신청자 정보를 포함하며, 고객의 인구통계학적 특성, 금융거래 이력, 대출 관련 속성 등 다양한 변수를 포함한 대표적 다변량 자료이다. 응답변수인 class는 신청자의 신용 상태를 나타내는 이진 변수로, Y=1은 신용 우량(good risk), Y=0은 신용 불량(bad risk)을 의미한다. 전체 표본에서 Good 비율은 약 70%, Bad 비율은 약 30%로 실제 금융기관의 대출 데이터에서 흔히 나타나는 비대칭적 클래스 분포를 가지고 있어, 분류 모델의 안정성과 예측 성능을 평가하는 데 적합한 환경을 제공한다. 독립변수는 총 20개로 구성되었으며 연속형과 범주형 변수가 혼합된 구조를 갖는다. 특히 전체 변수의 70% 이상이 범주형이며, 대부분이 3~10개의 범주를 지닌 다중범주(multi-level) 변수로 구성되어 분석 과정에서 모두 더미(dummy) 변환이 필요했다. 이에 따라 최종 입력 변수는 59개로 증가하여 데이터의 차원이 커졌다. 본 논문은 이러한 고차원·범주형 중심의 데이터 구조를 기반으로 MD-SDR과 PCA의 차원 축소 성능을 비교하고, 나아가 3단계 신용평가 시스템(DRA-CS)을 적용하여 두 기법이 생성한 신용점수(scorecard)의 차이를 종합적으로 평가하였다.

4. Case Study: 성능 비교

4.1 MD-SDR vs PCA 차원 축소 성능 비교

본 논문은 신용평가 데이터와 같이 범주형 비선형 구조가 강한 고차원 데이터에서 MD-SDR과 PCA를 동일한 데이터 조건에서 비교하였다. 각 방법이 생성하는 차원 축소 방향/loading vector)의 구조적 차이를 확인하고[그림2], 두 기법이 실제 예측 성능에서 어떤 차이를 보이는지 비교하였다.



[그림2] MD-SDR과 PCA가 생성한 가중치 차이

[그림2]는 16개의 주요 설명 변수에 대해 PCA와 MD-SDR이 산출한 가중치 벡터(weighted vector)를 비교한 그림이다. 큰 버블일수록 그 변수의 축 기여도가 크다는 것을 의미하며, PCA 또는 MD-SDR이 해당 변수를 얼마나 중요한 방향으로 사용했는지를 시각적으로 보여준다. PCA는 property_magnitude(자산보유정도), credit_amount(대출금액), duration(대출 기간), telephone(집전화 보유 여부)에 큰 가중치를 나타낸 반면, MD-SDR은 credit_history(과거 내역), checking_status (잔고상태), savings(저축액)에 큰 가중치를 나타낸 것을 확인할 수 있다.


PCA는 예측 목적과 무관하게 데이터 변동성이 큰 변수를 중심으로 형성하고 MD-SDR은 DCOV를 활용하여 Y와 X의 의존성을 최대화하는 방향을 찾기 때문에, 신용 위험과 관련된 변수들이 우선적으로 선택된다. 즉, PCA와 MD-SDR이 서로 전혀 다른 방식으로 정보를 요약하며, MD-SDR이 실제 신용평가 목표에 더 부합한 축을 생성한다는 점을 보여준다.

Methods	MD-SDR ($\hat{d}_{mmn} = 1$)	PCA($\hat{d}_{pca} = 1$)	PCA ($\hat{d}_{pca} = 18$)
PA	0.76	0.70	0.75
FPR	0.10	0.00	0.10
FNR	0.58	1.00	0.59
Precision	0.64	NA	0.63
Recall	0.42	0	0.41
F1-score	0.51	NA	0.50
AUC	0.66	0.50	0.65

[그림3] MD-SDR(1차원)과 PCA(1차원 및 18차원)의 예측 성능 비교


[그림3]은 MD-SDR(1차원)과 PCA(1차원 및 18차원)의 예측 성능을 10-fold cross-validation으로 평가한 결과이다. 이는 PCA가 많은 정보를 보존하려면 높은 차원을 유지해야 하지만 MD-SDR은 Subspace Distance Criterion에 따라 단 1차원만으로도 Y와의 관계를 충분히 설명할 수 있는 축을 생성하므로 단 1차원으로도 PCA 18차원과 동등하거나 그 이상의 예측 성능을 유지함을 보여준다.

4.2 3단계 신용평가 시스템(DRA-CS)을 적용 후 신용점수(scorecard) 성능 비교




[그림4] 신용평가 프로세스 3단계 접근법

본 연구에서는 차원축소 방식(MD-SDR, PCA, Stepwise Regression(SW))을 동일한 3단계 신용평가 시스템(DRA-CS)에 적용한 뒤, 각 기법이 생성한 신용점수(scorecard)가 실제 신청자의 위험도를 얼마나 정확히 반영하는지를 비교하였다. 평균 점수(average score)의 증가 패턴이 위험 수준과 얼마나 일관되게 대응되는지, 각 risk bin에 속하는 고객 수의 분포가 안정적으로 유지되는지, 각 bin에서의 오분류율(misclassification rate)이 얼마나 낮고 안정적인지 세가지 관점에서 비교 분석하였다.




[그림5] 위험 구간별 평균 점수 비교

[그림5]는 세 가지 방법이 산출한 신용점수를 1~10번 bin으로 나누어 평균 점수를 비교한 그림이다. bin 숫자가 높을수록 신용위험이 높은(high risk) 고객을 의미한다. 이상적인 신용점수는 bin이 증가할수록 평균 점수가 증가하는 단조 패턴을 보여야한다. PCA와 MD-SDR은 거의 동일한 부드러운 증가 패턴을 보이는 반면, SW는 low risk(1~4 bin)에서 평균 점수가 지나치게 낮고, high risk(9~10 bin)에서는 급격히 치솟는 불안정한 패턴을 보인다. 즉, PCA와 MD-SDR은 위험 수준이 증가할수록 점수가 일관적으로 증가하여 고객 간 위험도 차이를 더 잘 반영하기 때문에 구조적으로 안정적인 반면, SW는 평균 점수의 일관성이 떨어져 위험도 구분 능력이 낮은 비선형적 패턴을 보인다.



[그림6] 위험 구간별 고객 수 분포 비교

[그림 6]는 세 기법이 산출한 신용점수에 따라 고객들이 각 bin에 얼마나 분포되는지를 보여준다. 안정적인 신용점수는 각 bin에 적당히 균형 잡힌 수의 고객이 분포해야 한다. 하지만 SW는 bin 3과 4 등에서 고객 수가 비정상적으로 급감하거나 가장 큰 변동성을 보인다. 이러한 큰 변동성은 신용점수가 일관된 위험 기준을 반영하지 못한다는 것을 의미한다. 반대로 PCA와 MD-SDR은 전체적으로 변동 폭이 작고 고객들이 비교적 고르게 분포하기 때문에 실제 금융기관에서 신청자 등급을 현실적으로 분류하는 것을 확인 할 수 있다.



[그림7] 위험 구간별 오분류율 비교

오분류율이 높은 모델은 잘못된 대출 승인/거절 문제로 이어질 수 있기 때문에 매우 위험하다. 따라서 오분류율은 낮을수록 좋고, bin 전반에서 일정하게 유지될수록 신뢰도가 높다. [그림7]은 각 bin에서 모델이 실제 위험을 잘못 판단할 비율을 나타낸다. MD-SDR은 전체 bin에서 가장 낮거나 안정적인 오분류율을 보인다. 반면 PCA는 중간 수준의 오분류율을 보이지만 고위험 구간(특히 7~9 bin)에서 오분류율이 크게 증가한다. 또한 SW는 전 구간에서 변동성이 가장 크며, 특히 3 bin, 8 bin 등에서 오분류율이 급격하게 상승한다. 결국 MD-SDR의 낮고 안정적인 오분류율은 신용점수의 품질이 가장 우수하다는 것을 의미한다.

이 세 가지 결과는 MD-SDR 기반의 차원축소를 포함한 DRA-CS 시스템이 기존 PCA 또는 SW 기반 모델보다 훨씬 신뢰할 수 있는 평가 체계를 제공한다는 것을 보여준다.

5. 실제 데이터 적용

5.1. Loan Approval Classification Dataset 데이터 적용

Kaggle에서 ‘Loan Approval Classification Dataset’를 사용하여 실제 MD-SDR 방식이 기존의 PCA 차원축소 방식 보다 성능이 우수한지를 확인해보고자 한다. 위 데이터는 6개의 범주형, 8개의 수치형 변수로 구성되어 있으며 45,000개의 관측값을 가지고 있다. 반응변수는 대출의 승인, 거절을 나타내는 ‘loan_status’변수로 0과 1의 이진형 변수이다. 데이터에서 히스토그램의 분포, 기술통계량 등을 확인하며 대표성을 유지하는 수준에서 1000개를 임의추출하여 분석을 진행하였다. 전처리하는 논문과 같이 dummy coding을 하여 논문의 상황을 재연하는 것을 목표로 한다.

5.2 코드 구현 방법

본 연구에서는 차원축소를 위해 사용되는 Sufficient Dimension Reduction(SDR) 변환 행렬 $\beta^T \beta$ 의 추정을 목적으로 한다. 원 논문에서는 Stiefel 다양체 위에서의 리만 기하학 기반 최적화(Riemannian optimization) 기법을 적용하여 $\beta^T \beta$ 를 추정하였으나 실제 구현 단계에서는 계산 비용과 구현 난이도를 고려하여 보다 실용적인 접근법을 채택하였다.

5.2.1 Orthogonality Constraint를 고려한 최적화 방식

실제 구현에서는 Euclidean gradient 기반의 경사하강법을 사용하고, 각 반복마다 직교화 과정을 수행함으로써 Stiefel 다양체의 제약 조건인 $\beta^T \beta = I$ 를 만족하도록 하였다. 이 방식은 Wen & Yin(2013)의 “A feasible method for optimization with orthogonality constraints”에서 이론적으로 정당성이 확보된 방법이다. 해당 연구에서는 Euclidean gradient와 반복적 직교화 방식이 리만 최적화에서 얻는 해와 동일한 stationary point에 수렴함을 증명하였다. 따라서 본 연구의 구현 방식은 계산 효율성을 확보하면서도 이론적 일관성을 유지한다.


5.2.2 Subspace Estimation 이후의 Classification Modeling

최종적으로 추정된 SDR 변환 행렬 β 를 활용하여 원 자료를 저차원 subspace로 사영(Projection)하였다. 이후 축소된 특징 공간에서 로지스틱 회귀(logistic regression)를 적합하였다. 적합된 분류모형의 성능 평가는 각 모델의 Confusion matrix를 기반으로 주요 분류 지표(Accuracy, Precision, Recall, F1-score 등)를 산출하여 모형 간 비교 및 해석을 진행하였다.


5.2.3 Methodological Remark: DCOV 기반 SDR의 구조적 제약과 PCA 결합 가능성

DCOV 기반 SDR에서 사용되는 목적함수 $V(\beta^T X, Y)$ 는 스칼라 값으로 주어지는 단일 기준 함수이며, 본 연구에서 사용한 구현 방식에서 역시 DCOV 계산 결과가 스칼라 형태로 도출되어 추가 차원 정보를 확보할 수 없었다. 이 때문에 DCOV 기반 변환 결과에 PCA를 후처리로 적용하는 것이 구조적으로 불가능하였고 MMRN-PCA 조합 역시 동일한 이유로 실험에 포함시키지 못하였다. 향후 연구에서는 차원이 더 확보되는 환경이나 다른 형태의 DCOV 기반 구현을 통해 MMRN-SDR과 PCA 결합 효과까지 비교해보면 보다 정교한 분석이 가능할 것으로 기대된다.

5.3 결과 해석



[그림 8]



[그림 9]

[그림 8]은 MD-SDR 적용하여 차원별 AUC를 구한 결과이다. 최적의 4차원으로 도출되었다. [그림 9]는 PCA를 적용하여 차원별 AUC를 구한 경우이다. PCA의 경우 누적 설명력이 눈에 띄게 증가하는 구간은 2차원에서 약 0.85 이상을 확보하고, 90% 이상의 설명력을 얻기 위해서는 10차원이 필요한 것으로 나타났다. 그러나 전체 13개의 변수 중 10차원으로 축소하는 것은 차원축소의 효율성이 낮고 분석적 이점이 제한적이기 때문에, 정보 보존 측면에서 의미 있는 2차원 PCA 결과와 MD-SDR의 최적 차원인 4차원을 비교 대상으로 설정하여 이후 분석을 진행하였다.

MD-SDR			PCA(2)			PCA(4)		
Predicted	Actual		Predicted	Actual		Predicted	Actual	
	0	1		0	1		0	1
	0	696		82	0		730	112
1	47	175	1	43	115	1	49	122

[그림 10]

[그림 10]은 각 차원축소 기법을 적용한 후 로지스틱 회귀모형을 적합하여 산출한 예측값과 실제값을 비교한 confusion matrix를 제시한 것이다. 좌측부터 MD-SDR, 2차원 PCA, 4차원 PCA 순서이며, 클래스 0은 대출 미승인, 1은 대출 승인을 의미한다. MD-SDR의 경우 전체 1000개의 관측치 중 대출 승인으로 222건, 미승인으로 778건을 예측하였으며, 이 중 승인 예측 222건 중 175건, 미승인 예측 778건 중 696건을 올바르게 분류하여 총 871건을 정확히 예측하였다. 2차원 PCA는 전체 데이터 중 845건을 정확히 분류하였으며, 승인으로 예측한 158건 중 115건, 미승인으로 예측한 842건 중 730건을 올바르게 예측하였다. 4차원 PCA는 전체 데이터 중 846건을 정확히 분류하였고, 승인 예측 171건 중 122건, 미승인 예측 829건 중 724건을 올바르게 분류하였다. 이러한 결과를 통해 MD-SDR이 세 방법 중 가장 높은 정확도를 보이며 안정적인 분류 성능을 나타냄을 확인할 수 있다.

	Accuracy	FDR	FNR	Precision	Recall	F1-score	AUC
MD-SDR	0.871	0.212	0.319	0.789	0.681	0.731	0.9202
PCA 2	0.845	0.272	0.494	0.727	0.507	0.60	0.8681
PCA 4	0.846	0.286	0.463	0.713	0.537	0.613	0.8780

[그림 11]

[그림 11]은 각 방법별 confusion matrix에 대한 평가지표이다. 각 차원축소 기법에 대해 산출된 모형 평가 지표를 비교한 결과, 본 연구에서는 Accuracy, FDR, AUC 세 가지 지표에 초점을 맞추어 성능을 평가하였다. 먼저 Accuracy는 전체 관측치 중 정확히 분류된 비율로, 모형의 전반적인 분류 성능을 확인하기 위해 사용하였다. 두 번째로, 본 분석의 예측 대상이 ‘대출 승인(1)’임을 고려할 때 승인하면 안 되는 대상에게 대출을 승인하는 오류가 가장 큰 리스크로 작용할 수 있으므로, 대출 승인(1)이라고 예측한 관측치 중 실제로는 미승인(0)에 해당하는 비율인 ‘FDR(False Discovery Rate)’을 중요한 지표로 설정하였다. 마지막으로 모형이 positive와 negative를 얼마나 잘 구분하는지 보여주는 AUC를 통해 분류 능력을 보다 종합적으로 평가하였다. 세 지표 모두에서 MD-SDR 기반 모형이 가장 우수한 결과를 보여, MD-SDR이 정보 보존 측면뿐만 아니라 예측 성능 면에서도 효과적인 차원축소 방법임을 확인하였다.

6. 결론

본 논문에서는 고차원, 범주형, 비선형 구조를 지닌 신용평가 데이터에서 기존 차원 축소 기법의 한계를 극복하기 위해, Distance Covariance 기반 SDR에 MMRN 알고리즘으로 결합한 MD-SDR을 제안하고 그 효율성을 실증적으로 검증하였다. 3단계 신용평가 시스템(DRA-CS)을 적용한 결과, MD-SDR은 기존 연구 방법인 PCA 및 Stepwise보다 우수한 성능을 보였으며, 특히 고위험군 식별에서 안정성과 예측력이 돋보였다. 실제 신용평가 데이터를 활용해 적용한 결과 역시 이러한 논문의 결과와 일치하였다. 본 연구는 차원 축소의 효율성을 고려하여 각각 PCA의 누적 설명력이 크게 증가하는 부분인 2차원, 그리고 MD-SDR과 동일한 4차원으로 차원 축소를 진행하였다. 실제 예측 결과에서도 MD-SDR은 Accuracy, FDR, AUC 등 모든 핵심 지표에서 가장 우수한 성능을 보여, 단순한 분산 기반 축소 방식보다 목표변수 정보를 적극 활용하는 감독 기반 차원축소가 대출 승인과 같은 분류 문제에서 보다 효과적임을 확인하였다. 종합적으로, 본 연구 결과는 MD-SDR이 기존 차원축소 기법의 구조적 한계를 극복하고, 현대 신용평가 환경에서 요구되는 고차원, 범주형, 비선형 데이터를 효과적으로 처리할 수 있는 차세대 신용평가 기법임을 시사한다.